

# Finanzas

AUTHOR

Eduardo Selim Martínez Mayorga

PUBLISHED

May 10, 2022

# Finanzas

## Proyecto individual

Profesor: Eduardo Selim Martínez Mayorga

## Diagrama de flujo del notebook (Quarto)

Da click en una función para ir a su ficha (inputs → proceso → outputs).



# Librerías

▼ Code

```
import numpy as np
import pandas as pd
import yfinance as yf
import math
from functools import lru_cache
from sklearn.preprocessing import PolynomialFeatures
from sklearn.linear_model import LinearRegression
import matplotlib.pyplot as plt
```

▼ Code

```
TRADING_DAYS = 252 # días hábiles por año
```

## Descargar datos de Yahoo Finance

### get\_close

**Recibe:** `tickers`, `fecha_inicio`, `fecha_fin`

**Hace:** descarga precios de Yahoo Finance y devuelve un `DataFrame` con columnas=tickers.

► Code

### returns\_from\_close

**Recibe:** `close: DataFrame`

**Hace:** calcula retornos log o simples.

**Devuelve:** `DataFrame` de retornos.

► Code

## Estimadores

### ultimo\_precio

**Recibe:** - `ticker (str)`: símbolo (ej. "AAPL") - `fecha_inicio (str)`: fecha inicio "YYYY-MM-DD" - `fecha_fin (str)`: fecha fin "YYYY-MM-DD"

**Qué hace:** - Descarga la serie de precios de cierre (`Close` o `Adj Close`, según `get_close`) del ticker en el rango de fechas. - Toma el **último valor disponible** de la columna del ticker.

**Devuelve:** - `float` con el último precio observado:  $S_0$ .

► Code

## calcula\_media

---

**Recibe:** - ticker (str): símbolo (ej. "AAPL") - `fecha_inicio` (str): fecha inicio "YYYY-MM-DD" - `fecha_fin` (str): fecha fin "YYYY-MM-DD" - `kind` (str, default "log"): tipo de retorno: `log`:  $r_t = \log(P_t) - \log(P_{t-1})$

**Qué hace:** - Descarga precios del activo en el rango. - Construye la serie de retornos diarios con `returns_from_close`. - Calcula la media muestral de esos retornos.

**Devuelve:** - `float` con la media diaria:  $\mu_{\text{daily}} = \frac{1}{n} \sum_{t=1}^n r_t$ .

► Code

## calcula\_desv\_est

---

**Recibe:** - ticker (str): símbolo (ej. "AAPL") - `fecha_inicio` (str): fecha inicio "YYYY-MM-DD" - `fecha_fin` (str): fecha fin "YYYY-MM-DD" - `kind` (str, default "log"): tipo de retorno: `log`:  $r_t = \log(P_t) - \log(P_{t-1})$  - `ddof` (int, default 1): grados de libertad para la desviación estándar: ddof=1 → muestral (recomendado para estimación) ddof=0 → "poblacional" (divide entre  $n$ )

**Qué hace:** - Descarga precios. - Calcula retornos diarios. - Calcula la desviación estándar de retornos (por default, muestral).

**Devuelve:** - `float` con la volatilidad diaria estimada:  $\sigma_{\text{daily}}$ .

► Code

## calcula\_correlacion

---

**Recibe:** - ticker (str): símbolo (ej. "AAPL") - `fecha_inicio` (str): fecha inicio "YYYY-MM-DD" - `fecha_fin` (str): fecha fin "YYYY-MM-DD" - `kind` (str, default "log"): tipo de retorno (log o simple)

**Qué hace:** - Descarga precios de ambos tickers. - Construye retornos diarios alineados por fecha (esto es importante: correlación requiere observaciones pareadas). - Calcula la correlación muestral de Pearson entre las dos series de retornos.

**Devuelve:** - `float` con la correlación:  $\rho \in [-1, 1]$ .

► Code

# PAYOUTS (sin globals)

► Code

## SIMULACIÓN GBM (1 activo) CON MU HISTÓRICA (P)

El modelo buscamos simular es el movimiento browniano geométrico (GBM):

$$\$ dS_t = S_t dt + S_t dW_t. \$$$

La discretización para un paso de tamaño  $\Delta t$  es:

$$\$ S_{t+\Delta t} = S_t !(-\frac{1}{2}\sigma^2 t + \sqrt{\Delta t} Z), Z \sim N(0,1). \$$$

Por lo que tenemos dos factores indispensables: - El **drift** se multiplica por  $\Delta t$ . - El **término aleatorio** (browniano) se multiplica por  $\sqrt{\Delta t}$ .

En el código se construye  $W$  como una suma acumulada de normales estándar,  $W = \sum Z$ , y luego se usa  $\$ S_0 e^{(\mu - \frac{1}{2}\sigma^2)t + \sigma W} \$$ , lo cual equivale a asumir implícitamente  $\Delta t = 1$  (un paso de "tamaño 1") y además deja el parámetro `dt` sin afectar realmente la escala del proceso. Esto puede mezclar unidades (por ejemplo, interpretar  $T = 252/2$  como días mientras el proceso usa pasos de tamaño 1 sin conversión).

La corrección consiste en introducir explícitamente el tamaño del paso: si el paso es de `dt_days` días y se trabaja en años, entonces  $\$ t = . \$$  Con esto, la simulación correcta usa:  $\$ S_{k+1} = S_k !(-\frac{1}{2}\sigma^2 t + \sqrt{t} Z_k). \$$

Así, al cambiar `dt_days` o el horizonte `T_days`, el modelo se escala correctamente y las unidades de  $\mu$ ,  $\sigma$  y el descuento (por ejemplo con  $e^{-r\Delta t}$ ) quedan consistentes.

## genera\_simulaciones\_individual

Simula GBM con  $\Delta t = \frac{dt\_days}{252}$  y drift  $\mu$  histórica.

► Code

## LONGSTAFF–SCHWARTZ (1 activo)

## ejercicio\_americana\_LS

Longstaff–Schwartz: backward induction + regresión para decidir ejercicio temprano (1 activo).

► Code

## calcula\_precio\_americana

Calcula el precio como promedio del payoff descontado al tiempo de ejercicio.

► Code

## SIMULACIÓN CORRELACIONADA (2 activos) CON MU HISTÓRICA (P)

### genera\_simulaciones\_correlacionadas

Simula 2 GBM correlacionados vía Cholesky.

► Code

## LONGSTAFF–SCHWARTZ (PORTAFOLIO)

### ejercicio\_americana\_LS\_port

Longstaff–Schwartz sobre portafolio  $P = wS_1 + (1 - w)S_2$ .

► Code

### calcula\_precio\_americana\_port

Precio del derivado americano sobre el portafolio.

► Code

## BINOMIAL AMERICANA (sola)

### arbol\_americano

Árbol binomial americano (1 activo).

► Code

### arbol\_americano\_portafolio

Árbol binomial americano (portafolio con  $\sigma_P$ ).

► Code


# HISTOGRAMA

► Code

## EJEMPLOS DE USO


► Code

Precio LS (single, put, con mu): 5.784524227975639



Precio LS (port, put, con mu): 5.024886585850465

### Ejercicio (portafolio) | no ejerció: 863



Precio Binomial (single, call): 25.408046783678707

Precio Binomial (port, call): 29.09887840462954